

Wprowadzenie

Projekt obejmuje stworzenie systemu analizy tekstualnej i eksploracji danych (Text Mining) dla tekstów prawnych w języku polskim na przykładzie Konstytucji RP (z możliwością rozszerzenia do analizy ustaw w innych językach poprzez wykorzystanie odpowiednich słowników). System przetwarza surowy tekst prawny podzielony na artykuły w celu wyodrębnienia ukrytych struktur semantycznych, analizy sentymentu oraz wykrywania powiązań między pojęciami. Architektura systemu opiera się na dwuetapowym potoku przetwarzania (data pipeline): moduł ekstrakcji i wstępnego przygotowania danych zaimplementowano w języku Python, natomiast właściwy silnik analityczno-statystyczny oraz moduł generowania raportów zostały zaimplementowane w języku R.

Cele systemu

- Automatyczna identyfikacja kluczowych pojęć w artykułach tekstu prawnego bez konieczności ręcznej analizy prawniczej.
- Analiza częstości występowania terminów prawnych o sentymencie liberalnym (prawa, wolności) i restrykcyjnym (zakazy, obowiązki) w celu porównania różnych artykułów jednego tekstu lub kilku tekstów.
- Podział i pogrupowanie artykułów tekstu prawnego na grupy tematyczne
- Wykrywanie asocjacji między terminami prawnymi a kontekstami (np. w jakim kontekście jest używane słowo „wolność”).
- Sprawdzanie ważności słów w ustawie prawnej i jej artykułach przy pomocy metody TF-IDF.
- Wizualizacja wyników analizy przy pomocy chmur słów, wykresów wizualizujących tematy i asocjacje oraz wizualizacja klastrów.

Wymagania funkcjonalne

- **WF1 – przetwarzanie, oczyszczanie tekstu, stemming i tokenizacja:** System musi wczytać przygotowany plik wejściowy TXT, następnie przekonwertować go na plik CSV, oczyścić tekst (usunąć interpunkcje, polskie znaki, cyfry, znaki prawne i edytorskie, stop-words i specyficzne terminy prawne), sprowadzić słowa do form bazowych, po czym przekształcić tekst na macierz TDM i DTM.
- **WF2 – kategoryzacja słów, obliczanie indeksu:** System musi skategoryzować i podzielić terminy prawne w tekście na grupy „liberalne” (związane z prawem do, wolnością, równością itp.), „restrykcyjne” (związane z obowiązkami, zakazami, itp.) oraz „instytucjonalne” (związane z ustrojem państwa). Na podstawie częstości występowania terminów z danej kategorii w tekście bądź w jego poszczególnych artykułach system musi obliczyć indeks będący liczbową reprezentacją sentymentu danego tekstu lub artykułu.
- **WF3 – separacja terminów, negacja:** System musi poprawnie rozdzielić i skategoryzować terminy z negacją (np. można a nie można).
- **WF4 – analiza asocjacji:** System musi obliczyć wskaźnik korelacji Pearsona dla poszczególnych par słów wykrywając asocjacje między nimi i określając prawdopodobieństwo wystąpienia danego słowa, jeśli w tym samym artykule tekstu prawnego pojawi się inne słowo.
- **WF5 – modelowanie tematyczne LDA:** System musi zaimplementować model LDA w celu wydobycia ukrytych „tematów” w danym tekście prawnym i wizualizować wyniki przy pomocy sieci współwystępowania słów.
- **WF6 – analiza ważności słów TF-IDF:** System musi obliczyć statystykę TF-IDF dla każdego słowa w odniesieniu do poszczególnych artykułów, wskazując na wyrazy najbardziej znaczące dla danej sekcji.
- **WF7 – wizualizacja wyników:** System musi czytelnie przedstawiać wyniki analizy w postaci grafów, wykresów, chmur słów, macierzy itp., zapisać wyniki kategoryzacji

słownictwa w pliku w formacie CSV oraz wygenerować raport HTML z analizy danego tekstu.

Wymagania niefunkcjonalne:

- **WNF1 – środowisko i zależności:** System musi być kompatybilny z wersją R $\geq 4.3.0$ oraz Python ≥ 3.13 .
- **WNF2 – kompatybilność cross-browser:** Wygenerowany raport HTML musi być w pełni kompatybilny z silnikami renderującymi wiodących przeglądarek internetowych. (Chromium, Gecko, WebKit). Raporty muszą wyświetlać się poprawnie na przeglądarkach Google Chrome, Mozilla Firefox, Microsoft Edge oraz Apple Safari.
- **WNF3 – odporność na błędy w danych:** W przypadku błędnych danych wejściowych system musi odmówić ich analizy.
- **WNF4 – czytelność raportu:** Wygenerowany raport musi być czytelny oraz zawierać interaktywny podział na rozdziały.
- **WNF5 – zarządzanie pamięcią:** Przy analizie długich tekstów może dojść do wycieku pamięci (memory leak) więc system musi oczyścić pamięć po każdym kluczowym etapie analizy.

Interfejsy użytkownika i wymagania dotyczące danych

- **Interfejs użytkownika:** System działa w trybie skryptowym. Interfejsem wynikowym dla użytkownika końcowego jest raport HTML zawierający wykresy i tabele, który można otworzyć w dowolnej przeglądarce internetowej.
- **Wymagania dotyczące danych:**
 - **Dane wejściowe:** Plik strukturyzowany „konstytucja_artykuly.csv” gdzie w pierwszej kolumnie zawarte są identyfikatory artykułu a w drugiej ich pełne treści tekstowe. Tekst źródłowy Konstytucji Rzeczypospolitej Polskiej z dnia 2 kwietnia 1997 r. został pobrany z oficjalnego Internetowego Systemu Aktów Prawnych (ISAP) prowadzonego przez Kancelarię Sejmu (adres: isap.sejm.gov.pl), co gwarantuje autentyczność i referencyjność danych wejściowych.
 - **Dane wyjściowe:** Plik HTML zawierający analizę i jej wizualizację.

Słownictwo dokumentacji

- **stemming** – proces polegający na sprowadzeniu wyrazu do jego rdzenia
- **tokenizacja** – proces podziału ciągłego tekstu na mniejsze, autonomiczne jednostki lingwistyczne (w tym przypadku pojedyncze słowa)
- **LDA (Latent Dirichlet Allocation)** – ukryta alokacja Dirichleta, model probabilistyczny służący do mapowania dokumentów na ukryte tematy, gdzie każdy temat jest reprezentowany przez rozkład prawdopodobieństwa słów
- **TF-IDF (Term Frequency – Inverse Document Frequency)** – częstość terminów - odwrotna częstość w dokumentach; statystyka odzwierciedlająca znaczenie słowa w dokumencie w kontekście całego zbioru dokumentów (słowa często występujące tylko w jednym artykule będą „ważniejsze”)
- **analiza asocjacji** – technika eksploracji danych poszukująca związku i reguł typu „jeśli wystąpiło słowo A, to z prawdopodobieństwem X w tym samym artykule wystąpi słowo B”, reprezentowana przez wskaźnik korelacji Pearsona
- **macierz TDM (Term-Document Matrix)** – macierz w której kolumny odpowiadają artykułom, wiersze słowom, a komórki zawierają liczebność lub wagę danego słowa w artykule
- **macierz DTM (Document-Term Matrix)** – macierz w której wiersze odpowiadają artykułom, kolumny słowom, a komórki zawierają liczebność lub wagę danego słowa w artykule

- **stop-word** – wyrazy o wysokiej częstotliwości występowania, które nie niosą samodzielnej wartości semantycznej (np. spójniki)
- **memory leak** – wyciek pamięci, zjawisko w którym system zajmuje dużą ilość pamięci RAM której później nie zwalnia
- **text mining** – dziedzina zajmująca się analizą, przetwarzaniem i ekstrakcją wiedzy z języka naturalnego
- **indeks liberalności** – indeks liczony na podstawie ilości słów o nacechowaniu liberalnym i restrykcyjnym w danym artykule przedstawiający wydźwięk artykułu w postaci liczbowej (1 - najbardziej liberalny, -1 – najbardziej restrykcyjny)
- **negacja** – różnica w wydźwięku słów poprzedzonych słowem „nie”, zmieniająca kategoryzację danego słowa

Przypadki użycia

- **PU1: Generowanie pełnego profilu analitycznego Konstytucji RP**
 - **Aktor główny:** Analityk danych
 - **Warunek wstępny:** Plik „konstytucja.txt” znajduje się w katalogu roboczym projektu.
 - **Scenariusz główny:**
 - Użytkownik uruchamia skrypt przygotowawczy w języku Python w celu przekształcenia surowych tekstów źródłowych w ustrukturyzowany i wstępnie oczyszczony plik konstytucja_artykuly.csv.
 - Użytkownik eksportuje plik „konstytucja_artykuly.csv” do katalogu roboczego projektów R studio, a następnie inicjuje wykonanie skryptu analitycznego w R.
 - System ładuje plik CSV i przeprowadza czyszczenie tekstu.
 - System kolejno kategoryzuje nacechowanie słów, oblicza indeks liberalności dla całego tekstu i poszczególnych artykułów (sprawdzając przy tym rolę negacji), dokonuje analizy asocjacji, analizy tematów LDA i tworzy macierz częstości TF-IDF, równocześnie tworząc odpowiednią wizualizację dla każdej metody analizy.
 - System kompiluje wyniki i przebieg analizy w raporcie HTML.
- **PU2: Porównanie wydźwięku dwóch różnych tekstów prawnych**
 - **Aktor główny:** Analityk danych
 - **Warunek wstępny:** Dwa oddzielne katalogi robocze projektu, każdy zawierający plik „konstytucja_artykuly.csv” z innym tekstem wejściowym.
 - **Scenariusz główny:**
 - Użytkownik inicjuje wykonanie skryptu analitycznego w każdym z folderów roboczych.
 - System ładuje plik CSV i przeprowadza czyszczenie tekstu.
 - System kolejno kategoryzuje nacechowanie słów, oblicza indeks liberalności dla całego tekstu i poszczególnych artykułów (sprawdzając przy tym rolę negacji), dokonuje analizy asocjacji, analizy tematów LDA i tworzy macierz częstości TF-IDF, równocześnie tworząc odpowiednią wizualizację dla każdej metody analizy.
 - System kompiluje wyniki i przebieg analizy w raporcie HTML.
 - Użytkownik porównuje indeks liberalności obliczony dla każdego z tekstów.

Scenariusze użytkownika

- **US1:** Jako badacz prawa, chcę wygenerować model tematów LDA dla Konstytucji, aby sprawdzić, jakie główne idee (np. sądownictwo, finanse, prawa obywatelskie) automatycznie wyodrębniają się z tekstu bez mojej wiedzy a priori.
- **US2:** Jako analityk danych, chcę zastosować analizę asocjacji na artykułach, aby odkryć, które terminy prawne najsilniej ze sobą współwystępują i tworzą logiczne pary pojęciowe w polskim prawodawstwie.
- **US3:** Jako student prawa, chcę przeanalizować dany tekst prawny i jego wydźwięk (liberalny bądź restrykcyjny) jako część prowadzonej przeze mnie pracy naukowej mającej

na celu porównanie prawa pisanego w danym kraju z faktycznym stanem praw człowieka mierzonym według innego indeksu.