

Wprowadzenie

Projekt obejmuje stworzenie systemu analizy tekstowej i eksploracji danych (Text Mining) dla tekstów prawnych w języku polskim na przykładzie Konstytucji RP (z możliwością rozszerzenia do analizy ustaw w innych językach poprzez wykorzystanie odpowiednich słowników). System przetwarza surowy tekst prawny podzielony na artykuły w celu wyodrębnienia ukrytych struktur semantycznych, analizy charakteru języka oraz wykrywania powiązań między pojęciami. Projekt został zaimplementowany w języku R.

Cele systemu

Automatyczna identyfikacja kluczowych pojęć w artykułach tekstu prawnego bez konieczności ręcznej analizy prawniczej.

Analiza częstości występowania terminów prawnych o sentymencie liberalnym (prawa, wolności) i restrykcyjnym (zakazy, obowiązki) w celu porównania różnych artykułów jednego tekstu lub kilku tekstów.

Podział i pogrupowanie artykułów tekstu prawnego na grupy tematyczne

Wykrywanie asocjacji między terminami prawnymi a kontekstami (np. w jakim kontekście jest używane słowo „wolność”).

Sprawdzanie ważności słów w ustawie prawnej i jej artykułach przy pomocy metody TF-IDF.

Wizualizacja wyników analizy przy pomocy chmur słów, wykresów wizualizujących tematy i asocjacje oraz wizualizacja klastrów.

Wymagania funkcjonalne

WF1 – przetwarzanie, oczyszczanie tekstu, stemming i tokenizacja: System musi wczytać przygotowany plik wejściowy CSV, oczyścić tekst (usunąć interpunkcje, polskie znaki, cyfry, znaki prawne i edytorskie, stop-words i specyficzne terminy prawne), sprowadzić słowa do form bazowych, po czym przekształcić tekst na macierz TDM i DTM.

WF2 – kategoryzacja słów, obliczanie indeksu: System musi skategoryzować i podzielić terminy prawne w tekście na grupy „liberalne” (związane z prawem do, wolnością, równością itp.), „restrykcyjne” (związane z obowiązkami, zakazami, itp.) oraz „instytucjonalne” (związane z ustrojem państwa). Na podstawie częstości występowania terminów z danej kategorii w tekście bądź w jego poszczególnych artykułach system musi obliczyć indeks będący liczbową reprezentacją sentymentu danego tekstu lub artykułu.

WF3 – separacja terminów, negacja: System musi poprawnie rozdzielić i skategoryzować terminy z negacją (np. można a nie można).

WF4 – analiza asocjacji: System musi obliczyć wskaźnik korelacji Pearsona dla poszczególnych par słów wykrywając asocjacje między nimi i określając prawdopodobieństwo wystąpienia danego słowa, jeśli w tym samym artykule tekstu prawnego pojawi się inne słowo.

WF5 – modelowanie tematyczne LDA: System musi zaimplementować model LDA w celu wydobywania ukrytych „tematów” w danym tekście prawnym i wizualizować wyniki przy pomocy sieci współwystępowania słów.

WF6 – analiza ważności słów TF-IDF: System musi obliczyć statystykę TF-IDF dla każdego słowa w odniesieniu do poszczególnych artykułów, wskazując na wyrazy najbardziej znaczące dla danej sekcji.

WF7 – wizualizacja wyników: System musi czytelnie przedstawiać wyniki analizy w postaci grafów, wykresów, chmur słów, macierzy itp., zapisać wyniki kategoryzacji

słownictwa w pliku w formacie CSV oraz wygenerować raport HTML z analizy danego tekstu.

Wymagania niefunkcjonalne:

WNF1 – środowisko i zależności: System musi być kompatybilny z wersją R >= 4.3.0.

WNF2 – kompatybilność cross-browser: Wygenerowany raport HTML musi być w pełni kompatybilny z silnikami renderującymi wiodących przeglądarek internetowych. (Chromium, Gecko, WebKit). Raporty muszą wyświetlać się poprawnie na przeglądarkach Google Chrome, Mozilla Firefox, Microsoft Edge oraz Apple Safari.

WNF3 – odporność na błędy w danych: W przypadku błędnych danych wejściowych system musi odmówić ich analizy.

WNF4 – czytelność raportu: Wygenerowany raport musi być czytelny oraz zawierać interaktywny podział na rozdziały.

WNF5 – zarządzanie pamięcią: Przy analizie długich tekstów może dojść do wycieku pamięci (memory leak) więc system musi oczyścić pamięć po każdym kluczowym etapie analizy.

Interfejsy użytkownika i wymagania dotyczące danych

Interfejs użytkownika: System działa w trybie skryptowym. Interfejsem wynikowym dla użytkownika końcowego jest raport HTML zawierający wykresy i tabele, który można otworzyć w dowolnej przeglądarce internetowej.

Wymagania dotyczące danych:

- **Dane wejściowe:** Plik strukturyzowany „konstytucja_artykuly.csv” gdzie w pierwszej kolumnie zawarte są identyfikatory artykułu a w drugiej ich pełne treści tekstowe.
- **Dane wyjściowe:** Plik HTML zawierający analizę i jej wizualizację.

Potencjalny dalszy rozwój

Z uwagi na brak odpowiednich słowników do tego zadania, musieliśmy stworzyć własne, customowe słowniki. W przyszłości zamierzamy je rozwijać na bazie kolejnych tekstów prawnych. To samo dotyczy sekcji „ręczny stemming”. Rozwijanie słowników oraz sekcji stemmingu zwiększy dokładność i rzetelność analiz z użyciem naszego systemu.

Słownictwo dokumentacji

stemming – proces polegający na sprowadzeniu wyrazu do jego rdzenia

tokenizacja – proces podziału ciągłego tekstu na mniejsze, autonomiczne jednostki lingwistyczne (w tym przypadku pojedyncze słowa)

LDA (Latent Dirichlet Allocation) – ukryta alokacja Dirichleta, model probabilistyczny służący do mapowania dokumentów na ukryte tematy, gdzie każdy temat jest reprezentowany przez rozkład prawdopodobieństwa słów

TF-IDF (Term Frequency – Inverse Document Frequency) – częstość terminów - odwrotna częstość w dokumentach; statystyka odzwierciedlająca znaczenie słowa w dokumencie w kontekście całego zbioru dokumentów (słowa często występujące tylko w jednym artykule będą „ważniejsze”)

analiza asocjacji – technika eksploracji danych poszukująca związku i reguł typu „jeśli wystąpiło słowo A, to z prawdopodobieństwem X w tym samym artykule wystąpi słowo B”, reprezentowana przez wskaźnik korelacji Pearsona

macierz TDM (Term-Document Matrix) – macierz w której kolumny odpowiadają artykułom, wiersze słowom, a komórki zawierają liczebność lub wagę danego słowa w artykule

macierz DTM (Document-Term Matrix) – macierz w której wiersze odpowiadają artykułom, kolumny słowom, a komórki zawierają liczebność lub wagę danego słowa w artykule

stop-word – wyrazy o wysokiej częstotliwości występowania, które nie niosą samodzielnej wartości semantycznej (np. spójniki)

memory leak – wyciek pamięci, zjawisko w którym system zajmuje dużą ilość pamięci RAM której później nie zwalnia

text mining – dziedzina zajmująca się analizą, przetwarzaniem i ekstrakcją wiedzy z języka naturalnego

indeks liberalności – indeks liczony na podstawie ilości słów o nacechowaniu liberalnym i restrykcyjnym w danym artykule przedstawiający wydźwięk artykułu w postaci liczbowej (1 - najbardziej liberalny, -1 – najbardziej restrykcyjny)

negacja – różnica w wydźwięku słów poprzedzonych słowem „nie”, zmieniająca kategoryzację danego słowa

Przypadki użycia

PU1: Generowanie pełnego profilu analitycznego Konstytucji RP

- **Aktor główny:** Analityk danych
- **Warunek wstępny:** Plik „konstytucja_artykuly.csv” znajduje się w katalogu roboczym projektu.
- **Scenariusz główny:**
 - Użytkownik inicjuje wykonanie skryptu analitycznego.
 - System ładuje plik CSV i przeprowadza czyszczenie tekstu.
 - System kolejno kategoryzuje nacechowanie słów, oblicza indeks liberalności dla całego tekstu i poszczególnych artykułów (sprawdzając przy tym rolę negacji), dokonuje analizy asocjacji, analizy tematów LDA i tworzy macierz częstości TF-IDF, równocześnie tworząc odpowiednią wizualizację dla każdej metody analizy.
 - System kompiluje wyniki i przebieg analizy w raporcie HTML.

PU2: Porównanie wydźwięku dwóch różnych tekstów prawnych

- **Aktor główny:** Analityk danych
- **Warunek wstępny:** Dwa oddzielne katalogi robocze projektu, każdy zawierający plik „tekstprawnyX_artykuly.csv” z innym tekstem wejściowym.
- **Scenariusz główny:**
 - Użytkownik inicjuje wykonanie skryptu analitycznego w każdym z folderów roboczych.
 - System ładuje plik CSV i przeprowadza czyszczenie tekstu.
 - System kolejno kategoryzuje nacechowanie słów, oblicza indeks liberalności dla całego tekstu i poszczególnych artykułów (sprawdzając przy tym rolę negacji), dokonuje analizy asocjacji, analizy tematów LDA i tworzy macierz częstości TF-IDF, równocześnie tworząc odpowiednią wizualizację dla każdej metody analizy.
 - System kompiluje wyniki i przebieg analizy w raporcie HTML.
 - Użytkownik porównuje indeks liberalności obliczony dla każdego z tekstów.

Scenariusze użytkownika

US1: Jako badacz prawa, chcę wygenerować model tematów LDA dla Konstytucji, aby sprawdzić, jakie główne idee (np. sądownictwo, finanse, prawa obywatelskie) automatycznie wyodrębniają się z tekstu bez mojej wiedzy a priori.

US2: Jako analityk danych, chcę zastosować analizę asocjacji na artykułach, aby odkryć, które terminy prawne najsilniej ze sobą współwystępują i tworzą logiczne pary pojęciowe w polskim prawodawstwie.

US3: Jako student prawa, chcę przeanalizować dany tekst prawny i jego wydźwięk (liberalny bądź restrykcyjny) jako część prowadzonej przeze mnie pracy naukowej mającej na celu porównanie prawa pisanego w danym kraju z faktycznym stanem praw człowieka mierzonym według innego indeksu.